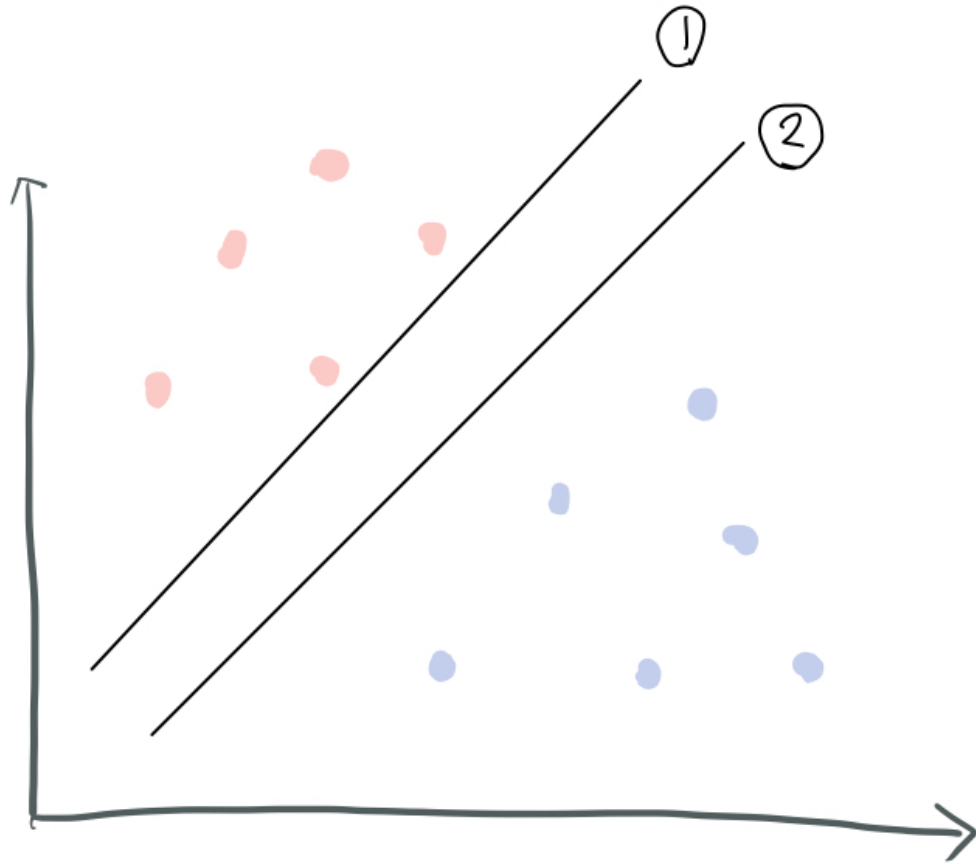


A logo consisting of a blue circle with a textured, hand-drawn appearance. Inside the circle, the letters "ML" are written in a bold, black, sans-serif font.

ML

Support Vector Machine




$$d(X) = W^T X + b = 0$$

Decision hyperplane

수학적 특징:

- feature space를 두 영역으로 분할 함
- 임의의 상수 c 를 곱하여도 같은 초평면
- W 는 초평면의 법선벡터로, 방향을 나타내고 b 는 위치를 나타냄
- 임의의 점 X 에서 초평면까지의 거리는 $h = \frac{|d(x)|}{\|W\|}$

Linear SVM | 선형분리가 가능한 경우



⊕ 샘플에 대해서

$$w^T x + b \geq a$$

$$y_i = \begin{cases} +1 & \text{for } \oplus \text{ 샘플} \\ -1 & \text{for } \ominus \text{ 샘플} \end{cases} \quad \text{즉 두면}$$

⊖ 샘플에 대해

$$w^T x + b \leq -a$$

$$y_i (\bar{w}^T \bar{x}_i + b) \geq a$$

조건부 최적화 문제:

$$t_i(W^T X_i + b) - 1 \geq 0, i = 1, \dots, N$$

$$\text{Minimize } J(w) = \frac{1}{2} \|W\|^2$$

문제의 특징:

해의 유일성: $j(w)$ 는 2차식이므로 convex function. \rightarrow no local minimum.

어려운 문제: N개의 선형 부등식을 조건으로 가진 2차 함수의 최적화 문제.

\rightarrow Lagrange multiplier 도입

Lagrange function

$$L(w, b, \alpha) = \frac{1}{2} \|W\|^2 - \sum_{i=1}^N \alpha_i (t_i (W^T X_i + b) - 1)$$

Karush-Kuhn-Tucker (KKT) 조건을 이용

KKT조건:

1. $\frac{\partial L(W, b, \alpha)}{\partial W} = 0 \rightarrow W = \sum_{i=1}^N \alpha_i t_i X_i$

2. $\frac{\partial L(W, b, \alpha)}{\partial b} = 0 \rightarrow \sum_{i=1}^N \alpha_i t_i = 0$

3. $\alpha_i \geq 0, \quad i = 1, \dots, N$

4. $\alpha_i (t_i (W^T X_i + b) - 1) = 0, \quad i = 1, \dots, N$

t_i 와 X_i 는 주어진 데이터 $\rightarrow \alpha_i$ 만 구하면 됨.

$t_i (W^T X_i + b) = 1$ 인 i 들이 **Support Vectors**

대입하고 정리하면,

조건

$$\sum_{i=1}^N \alpha_i t_i = 0,$$

$$\alpha_i \geq 0, \quad i = 1, \dots, N$$

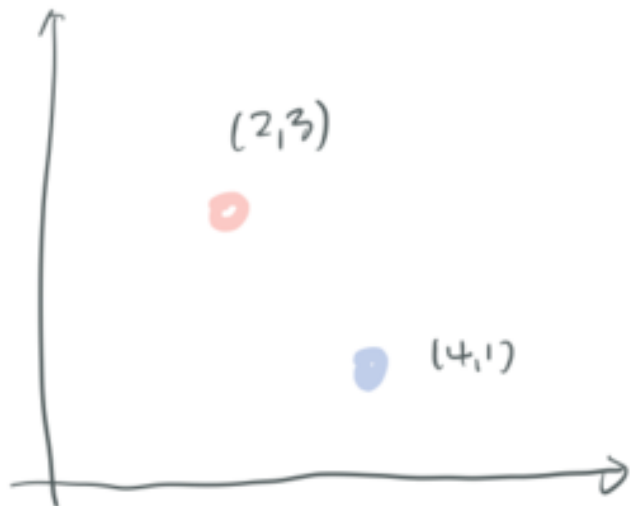
하에,

$$\tilde{L}(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j X_i^T X_j \text{ 를 최대화.}$$

→ 하나의 등식 조건과, N 개의 부등식 조건을 가진 2차 (quadratic) 목적 함수의 최대화 문제.

목적함수에서 두 벡터의 내적으로 계산.

Linear SVM | Example



$$X_1 = (2, 3)^T, \quad t_1 = 1$$

$$X_2 = (4, 1)^T, \quad t_2 = -1$$

$$a_1 t_1 + a_2 t_2 = 0$$

$$a_1 \geq 0, \quad a_2 \geq 0 \quad \text{일 때,}$$

$$\tilde{L}(a) = (\alpha_1 + \alpha_2)$$

$$- \frac{1}{2} (\alpha_1 \alpha_1 t_1 t_1 x_1^T x_1 + \alpha_1 \alpha_2 t_1 t_2 x_1^T x_2 + \alpha_2 \alpha_1 t_2 t_1 x_2^T x_1 + \alpha_2 \alpha_2 t_2 t_2 x_2^T x_2) \quad \text{를 최대화}$$

Linear SVM | Example

$$\alpha_1 - \alpha_2 = 0$$

$$\alpha_1 \geq 0, \alpha_2 \geq 0 \text{ 일 때,}$$

$$\tilde{L}(\alpha) = (\alpha_1 + \alpha_2) - \frac{1}{2} (13\alpha_1^2 + 11\alpha_2^2 - 22\alpha_1\alpha_2) \text{ 를 최대화}$$

$$\alpha_1 = \alpha_2$$

$$\tilde{L}(\alpha) = -4\alpha^2 + 2\alpha$$

$$= -4\left\{\left(\alpha - \frac{1}{4}\right)^2 - \frac{1}{16}\right\}$$

$$\therefore \alpha_1 = \alpha_2 = \frac{1}{4} \text{ 이서 최대값.}$$

$$W = \sum_{i=1}^N \alpha_i t_i x_i = \frac{1}{4} (2, 3)^T - \frac{1}{4} (4, 1)^T = \left(-\frac{1}{2}, \frac{1}{2}\right)^T$$

$$b \rightarrow \alpha_2 (t_2 (W^T x_i + b) - 1) = 0$$

$$\frac{1}{4} \left[\left(-\frac{1}{2}, \frac{1}{2}\right) \begin{pmatrix} 2 \\ 3 \end{pmatrix} + b - 1 \right] = 0$$
$$b - \frac{1}{2} = 0 \rightarrow b = \frac{1}{2}$$

$$\therefore d(x) = W^T x + b = \left(-\frac{1}{2}, \frac{1}{2}\right) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \frac{1}{2}$$
$$= -\frac{1}{2}x_1 + \frac{1}{2}x_2 + \frac{1}{2}$$

Linear SVM | 선형분리가 불가능한 경우




$$t(w^T x + b) \geq 1$$

$$\xi = 0$$



$$0 \leq t(w^T x + b) < 1$$

$$0 < \xi \leq 1$$




$$t(w^T x + b) < 0$$

$$\xi > 1$$

$$t(w^T x + b) \geq 1 - \xi$$

SVM Loss



$$J(w, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$



$$\sum_{i=1}^N \alpha_i t_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, \dots, N \quad \text{일 때,}$$

$$\tilde{L}(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j x_i^T x_j \quad \text{를 최대화}$$

Kernel function: 다른 공간으로 사상 된 두 벡터의 내적

SVM Kernel function의 성질:

L 공간 상의 두 벡터 X 와 Y 를 매개 변수로 갖는 커널 함수를 $K(X, Y)$ 라 할 때,

$K(X, Y) = \phi(X) \cdot \phi(Y)$ 를 만족하는 맵핑 함수 $\phi(\cdot)$ 이 존재해야 한다.


즉 커널 함수의 값과, H 공간 상으로 맵핑된 두 점 $\phi(X)$ 와 $\phi(Y)$ 의 내적이 같아야 한다.

하나의 kernel function에 대응하는 맵핑 함수는 여러 개 존재 가능.

$$\tilde{L}(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j \underline{X_i^T X_j}$$

실제 계산은 저차원 L 공간에서 이루어지지만 분류 작업은 고차원 공간인 H 공간에서 수행되는 효과

$$\tilde{L}(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j t_i t_j \underline{\phi(X_i)^T \phi(X_j)}$$



$$K(X_i, X_j)$$

Polynomial

$$K(X, Y) = (X \cdot Y + 1)^p$$


RBF (Radial Basis Function)

$$K(X, Y) = e^{-\|X-Y\|^2/2\sigma^2}$$


Hyperbolic tangent

$$K(X, Y) = \tanh(\alpha X \cdot Y + \beta)$$

SVM은 기본적으로 이진분류기 !




OAA(One Against All) 혹은 One-versus-rest(OVR)



→ $d(i)$ 값을 비교하여 결정

OVO(One-versus-one)



→ Majority voting